

## Sivas Cumhuriyet Üniversitesi

### Şarkışla Uygulamalı Bilimler Yüksekokulu

Derin Öğrenme Dersi

## DERİN ÖĞRENME MODEL EĞİTİMİ

### PROJE ÖDEVİ RAPORU

| Alan             | Bilgi                               |
|------------------|-------------------------------------|
| Proje Başlığı    | Yapay Zeka ile Çiçek Tanıma Sistemi |
| Öğrenci Ad Soyad | Emirhan Ertürk                      |
| Öğrenci No       | 2023481038                          |
| Danışman         | Dr. Öğr. Üyesi Mehmet Akif Buzpınar |
| Dönem            | 2025 - 2026 Bahar                   |
| Teslim Tarihi    | 12.06.2026                          |

## ÖZET

Bu çalışmada TensorFlow tarafından açık olarak sunulan flower\_photos veri seti kullanılarak beş farklı çiçek türünü sınıflandıran bir derin öğrenme sistemi geliştirilmiştir. Veri seti papatya (daisy), karahindiba (dandelion), gül (roses), ayçiçeği (sunflowers) ve lale (tulips) sınıflarından oluşmaktadır. Projenin temel amacı, kullanıcı tarafından yüklenen bir çiçek fotoğrafının türünü otomatik olarak tahmin eden ve web arayüzü üzerinden test edilebilen bir yapay zeka uygulaması oluşturmaktır.

Çalışmada 10 farklı algoritma ve mimari; doğruluk potansiyeli, eğitim maliyeti, tahmin hızı, model boyutu ve web arayüzüne uygunluk açısından karşılaştırılmıştır. Karşılaştırma sonucunda hafif yapısı, transfer öğrenmeye uygunluğu ve hızlı tahmin üretmesi nedeniyle MobileNetV2 en uygun model olarak seçilmiştir. MobileNetV2, ImageNet üzerinde önceden eğitilmiş ağırlıklarla kullanılmış, temel katmanları dondurulmuş ve çıkışa beş sınıflı yoğun katman eklenmiştir.

Eğitim sürecinde Adam optimizasyon algoritması, Sparse Categorical Crossentropy kayıp fonksiyonu, 224x224 giriş boyutu ve 32 batch boyutu kullanılmıştır. Model 10 epoch boyunca eğitilmiş ve doğrulama/test sonuçlarında yaklaşık %91 doğruluk seviyesine ulaşmıştır. Sınıf bazlı sonuçlarda dandelion sınıfı en yüksek F1-score değerini göstermiş, roses ve tulips sınıfları arasında ise bazı görsel benzerliklerden dolayı karışıklıklar oluşmuştur. Son aşamada Gradio framework kullanılarak fotoğraf yüklenebilen bir web arayüzü hazırlanmıştır.

**Anahtar Kelimeler:** Derin öğrenme, CNN, transfer öğrenme, MobileNetV2, TensorFlow, görüntü sınıflandırma, Gradio.

## 1. Giriş

Görüntü tanıma, bilgisayarların dijital görseller içindeki nesneleri, renkleri, kenarları ve desenleri analiz ederek anlamlı sonuçlar üretmesini sağlayan önemli bir yapay zeka alanıdır. Günümüzde tarım, sağlık, güvenlik, otonom araçlar, mobil uygulamalar ve akıllı kamera sistemleri gibi birçok alanda kullanılmaktadır. Derin öğrenme yöntemleri, özellikle büyük miktarda görsel veriden özellik öğrenebilmesi sayesinde görüntü sınıflandırma problemlerinde geleneksel yöntemlere göre daha başarılı sonuçlar vermektedir.

### 1.1 Problem Tanımı

Bu projede ele alınan problem, verilen bir çiçek fotoğrafının hangi çiçek türüne ait olduğunun otomatik olarak belirlenmesidir. Gerçek hayatta aynı çiçeğin farklı ışık koşullarında, farklı açılardan veya farklı arka planlar üzerinde görüntülenmesi sınıflandırmayı zorlaştırır. Ayrıca gül ve lale gibi bazı sınıflar renk ve yaprak yapısı açısından benzer görünebilir. Bu nedenle sistemin yalnızca renge değil, çiçeğin genel şekline, yaprak düzenine ve görsel desenlerine göre öğrenmesi gerekir.

### 1.2 Çalışmanın Amacı

Çalışmanın amacı; papatya, karahindiba, gül, ayçiçeği ve lale türlerini sınıflandırabilen derin öğrenme tabanlı bir model geliştirmek, 10 algoritmayı karşılaştırmak ve seçilen en iyi algoritmayı detaylı olarak açıklamaktır. Ayrıca geliştirilen modelin bir web arayüzü üzerinden kullanılabilir hale getirilmesi hedeflenmiştir. Bu sayede proje yalnızca model eğitimiyle sınırlı kalmamış, kullanıcı tarafından test edilebilen gerçek bir uygulama haline getirilmiştir.

### 1.3 Raporun Organizasyonu

- Bölüm 2: Veri seti ve ön işleme adımları açıklanmıştır.
- Bölüm 3: 10 algoritma/mimari karşılaştırılmış ve MobileNetV2 mimarisi detaylandırılmıştır.
- Bölüm 4: Eğitim süreci, hiperparametreler ve eğitim gözlemleri verilmiştir.
- Bölüm 5: Performans metrikleri, sınıf bazlı sonuçlar ve karışıklık matrisi yorumlanmıştır.
- Bölüm 6: Güçlü ve zayıf yönler ile iyileştirme önerileri tartışılmıştır.
- Bölüm 7: Sonuç ve gelecek çalışmalar sunulmuştur.

## 2. VERİ SETİ VE ÖN İŞLEME

### 2.1 Veri Seti Tanımı

Projede TensorFlow örnek görsel veri setlerinden flower\_photos kullanılmıştır. Kodda veri seti Google Storage bağlantısından indirilmiş, klasör yapısı otomatik aranmış ve TensorFlow image\_dataset\_from\_directory fonksiyonu ile eğitim/doğrulama olarak okunmuştur. Veri setinin klasör yapısında her sınıf kendi klasörü altında bulunduğu için etiketler otomatik olarak oluşturulmuştur.

| Özellik             | Değer                                       |
|---------------------|---------------------------------------------|
| Veri Seti Adı       | flower_photos                               |
| Kaynak              | TensorFlow example_images / Google Storage  |
| Toplam Örnek Sayısı | Yaklaşık 3.670 görsel                       |
| Sınıf Sayısı        | 5                                           |
| Sınıflar            | daisy, dandelion, roses, sunflowers, tulips |
| Girdi Boyutu        | 224 x 224 piksel, 3 kanal RGB               |
| Veri Türü           | Görüntü                                     |

Tablo 1. Veri seti genel özellikleri.

### 2.2 Sınıf Dağılımı

Veri setindeki sınıfların dağılımı modelin dengeli öğrenmesi açısından önemlidir. Sınıflar arasında çok büyük bir dengesizlik bulunmaması, modelin tek bir sınıfa aşırı yönelmesini azaltır.

| Sınıf Adı               | Yaklaşık Örnek Sayısı | Oran (%) |
|-------------------------|-----------------------|----------|
| Daisy / Papatya         | 633                   | 17,25    |
| Dandelion / Karahindiba | 898                   | 24,47    |
| Roses / Gül             | 641                   | 17,47    |
| Sunflowers / Ayçiçeği   | 699                   | 19,05    |
| Tulips / Lale           | 799                   | 21,77    |
| TOPLAM                  | 3.670                 | 100,00   |

Tablo 2. Veri setindeki sınıfların yaklaşık dağılımı.




Figure 1 Veri setindeki çiçek türlerinin dağılımı.

## 2.3 Veri Ön İşleme

Veri ön işleme adımları, modelin görüntüleri doğru boyutta ve doğru sayısal aralıkta almasını sağlar. Bu projede aşağıdaki işlemler uygulanmıştır:

- Tüm görseller 224x224 piksel boyutuna getirilmiştir.
- Veri seti validation\_split=0.2 ile %80 eğitim ve %20 doğrulama olarak ayrılmıştır.
- Batch boyutu 32 seçilmiştir.
- Rescaling(1./127.5, offset=-1) katmanı ile piksel değerleri MobileNetV2 için uygun aralığa taşınmıştır.
- seed=123 kullanılarak veri ayrımının tekrar üretilebilir olması sağlanmıştır.

## 2.4 Eğitim ve Doğrulama Ayrımı

Modelin yalnızca eğitim verilerini ezberleyip ezberlemediğini anlamak için veri seti eğitim ve doğrulama kümelerine ayrılmıştır. Eğitim kümesi modelin ağırlıklarını öğrenmesi için kullanılırken, doğrulama kümesi modelin daha önce görmediği veriler üzerindeki başarısını ölçmek için kullanılmıştır.

## 3. ALGORİTMA KARŞILAŞTIRMASI VE MODEL MİMARİSİ

### 3.1 Karşılaştırılan 10 Algoritma / Mimari

Proje için kullanılabilecek 10 farklı algoritma veya mimari; doğruluk potansiyeli, eğitim maliyeti, tahmin hızı, model boyutu ve web arayüzünde kullanılabilirlik ölçütlerine göre karşılaştırılmıştır. Bu karşılaştırma, hangi modelin proje hedeflerine daha uygun olduğunu belirlemek için yapılmıştır. Projede fiilen eğitilen model MobileNetV2 tabanlı transfer öğrenme modelidir.

| #  | Algoritma / Model | Başarı Potansiyeli | Hız / Boyut        | Değerlendirme                                                              |
|----|-------------------|--------------------|--------------------|----------------------------------------------------------------------------|
| 1  | Klasik CNN        | Orta-Yüksek        | Orta / Orta        | Sıfırdan eğitilir. Küçük veri setinde aşırı öğrenme riski vardır.          |
| 2  | VGG16             | Yüksek             | Yavaş / Büyük      | Parametre sayısı fazla olduğu için web arayüzü için ağırdır.               |
| 3  | ResNet50          | Yüksek             | Orta-Yavaş / Büyük | Derin ağlarda başarılıdır; donanım ihtiyacı fazladır.                      |
| 4  | InceptionV3       | Yüksek             | Orta / Orta-Büyük  | Farklı filtre boyutlarıyla iyi özellik çıkarır; mimarisi daha karmaşıktır. |
| 5  | EfficientNetB0    | Çok Yüksek         | Orta / Orta        | Doğruluk ve verim dengesinde başarılıdır.                                  |
| 6  | MobileNetV2       | Yüksek             | Hızlı / Küçük      | Hafif, hızlı ve web/mobil kullanım için en uygun modeldir.                 |
| 7  | DenseNet121       | Yüksek             | Orta-Yavaş / Büyük | Özellik aktarımı güçlüdür; eğitim maliyeti fazladır.                       |
| 8  | Xception          | Yüksek             | Orta / Büyük       | Derin özellik çıkarımı güçlüdür ancak MobileNet kadar hafif değildir.      |
| 9  | NASNetMobile      | Yüksek             | Orta / Orta        | Mobil odaklıdır; mimari karmaşıklığı daha fazladır.                        |
| 10 | SVM + HOG         | Düşük-Orta         | Hızlı / Küçük      | Derin öğrenme değildir; karmaşık çiçek görsellerinde sınırlı kalır.        |

**Tablo 3. Projede değerlendirilen 10 algoritma/mimari karşılaştırması.**

### 3.2 En İyi Algoritmanın Seçilmesi

Karşılaştırma sonucunda en uygun algoritma MobileNetV2 olarak belirlenmiştir. MobileNetV2 düşük parametre sayısına rağmen güçlü özellik çıkarılabilir, ImageNet ağırlıklarıyla transfer öğrenmeye uygundur ve Gradio web arayüzünde hızlı tahmin üretir. VGG16, ResNet50 ve DenseNet gibi modeller başarılı olsa da daha büyük ve yavaştır. SVM + HOG ise çiçek fotoğraflarındaki ışık, açı ve arka plan değişimlerini derin CNN modelleri kadar iyi öğrenemez.

| Ölçüt              | MobileNetV2 İçin Değerlendirme                                |
|--------------------|---------------------------------------------------------------|
| Doğruluk           | Yaklaşık %91 doğruluk ile başarılı sonuç vermiştir.           |
| Hız                | Hafif yapısı sayesinde hızlı tahmin üretir.                   |
| Model Boyutu       | Diğer derin modellere göre daha küçüktür.                     |
| Uygulama Uygunluğu | Gradio web arayüzünde pratik şekilde kullanılabilir.          |
| Transfer Öğrenme   | ImageNet ağırlıklarıyla küçük veri setlerinde avantaj sağlar. |

Tablo 4. MobileNetV2 seçiminin temel gerekçeleri.

### 3.3 MobileNetV2 Model Mimarisi

MobileNetV2, mobil ve düşük kaynaklı sistemlerde çalışmak üzere tasarlanmış hafif bir evrimsel sinir ağıdır. Depthwise separable convolution yapısı kullanarak standart evrimsellere göre daha az işlemle özellik çıkarımı yapar. Bu sayede model hem hızlı çalışır hem de görüntü sınıflandırma görevlerinde yeterli doğruluk sağlar. Projede ImageNet üzerinde önceden eğitilmiş MobileNetV2 tabanı kullanılmış, temel katmanlar dondurulmuş ve çıkışa GlobalAveragePooling2D ile Dense(5) katmanı eklenmiştir.

| # | Katman                 | Tür                   | Görev                                     |
|---|------------------------|-----------------------|-------------------------------------------|
| 1 | Input                  | 224x224x3 RGB         | Görüntüyü modele alır.                    |
| 2 | Rescaling              | Normalizasyon         | Piksel değerlerini uygun aralığa getirir. |
| 3 | MobileNetV2            | Önceden eğitilmiş CNN | Görsel özellik çıkarımı yapar.            |
| 4 | GlobalAveragePooling2D | Havuzlama             | Özellik haritalarını özetler.             |
| 5 | Dense(5)               | Çıkış katmanı         | 5 çiçek sınıfı için skor üretir.          |

Tablo 5. Kullanılan MobileNetV2 tabanlı modelin katman yapısı.

### 3.4 Transfer Öğrenme

Model sıfırdan eğitilmemiştir. ImageNet üzerinde eğitilmiş MobileNetV2 tabanı kullanılmıştır. temel\_model.trainable = False komutu ile önceden öğrenilmiş katmanlar dondurulmuştur. Böylece model daha önce milyonlarca görsel üzerinden öğrendiği kenar, renk, doku ve şekil özelliklerini bu projede kullanabilmiştir. Sadece son sınıflandırma katmanı proje veri setindeki beş çiçek sınıfına göre öğrenmiştir.

### 3.5 Modelin Çalışma Mantığı

1. Kullanıcı sisteme bir çiçek fotoğrafı yükler.

2. Görsel 224x224 piksel boyutuna getirilir.
3. Piksel değerleri MobileNetV2 için uygun aralığa dönüştürülür.
4. MobileNetV2 görselden ayırt edici özellikleri çıkarır.
5. Dense çıkış katmanı her çiçek sınıfı için skor üretir.
6. Softmax ile olasılıklar hesaplanır ve en yüksek olasılıklı sınıf sonuç olarak gösterilir.

## 4. EĞİTİM SÜRECİ

### 4.1 Hiperparametreler

| Hiperparametre   | Değer                                           | Gerekçe                                                                     |
|------------------|-------------------------------------------------|-----------------------------------------------------------------------------|
| Epoch Sayısı     | 10                                              | Transfer öğrenme ile kısa sürede yeterli başarı hedeflenmiştir.             |
| Batch Boyutu     | 32                                              | Colab ortamında bellek ve hız dengesi sağlar.                               |
| Giriş Boyutu     | 224x224                                         | MobileNetV2 ile uyumludur.                                                  |
| Optimizer        | Adam                                            | Hızlı yakınsama sağlar ve görüntü sınıflandırmada yaygın kullanılır.        |
| Öğrenme Hızı     | 0.0005                                          | Dengeli öğrenme sağlar; çok yüksek değerlerde kararsızlık oluşmasını önler. |
| Kayıp Fonksiyonu | SparseCategoricalCrossentropy(from_logits=True) | Etiketler sayısal olduğu için çok sınıflı sınıflandırmaya uygundur.         |
| Metrik           | Accuracy                                        | Doğru tahmin oranını izler.                                                 |
| Doğrulama Ayrımı | %20                                             | Görülmeeyen veri başarısını ölçer.                                          |

**Tablo 6. Eğitim sürecinde kullanılan hiperparametreler**

## 4.2 Donanım ve Ortam Bilgileri

| Bileşen                   | Bilgi                                                  |
|---------------------------|--------------------------------------------------------|
| Eğitim Ortamı             | Google Colab                                           |
| Programlama Dili          | Python                                                 |
| Derin Öğrenme Kütüphanesi | TensorFlow / Keras                                     |
| Arayüz Kütüphanesi        | Gradio                                                 |
| Grafik Kütüphaneleri      | Matplotlib, Seaborn                                    |
| Ek Analiz                 | Scikit-learn confusion matrix ve classification report |

*Tablo 7. Donanım ve yazılım ortamı.*

## 4.3 Eğitim Süreci Gözlemleri

Eğitim sırasında doğruluk değerinin epoch ilerledikçe arttığı, kayıp değerinin ise azaldığı gözlemlenmiştir. Eğitim başarısı yaklaşık %95 seviyelerine, doğrulama başarısı ise yaklaşık %91 bandına ulaşmıştır. Eğitim ve doğrulama eğrilerinin birbirine yakın ilerlemesi modelin yalnızca ezber yapmadığını, yeni görüntüler üzerinde de başarılı sonuçlar üretebildiğini göstermektedir.

| Epoch | Eğitim Doğruluğu | Doğrulama Doğruluğu | Eğitim Kaybı  | Doğrulama Kaybı | Yorum                           |
|-------|------------------|---------------------|---------------|-----------------|---------------------------------|
| 1     | Yaklaşık %63     | Yaklaşık %83        | Yaklaşık 1.00 | Yaklaşık 0.59   | Başlangıç öğrenmesi.            |
| 2     | Yaklaşık %85     | Yaklaşık %87        | Yaklaşık 0.48 | Yaklaşık 0.44   | Hızlı öğrenme artışı.           |
| 5     | Yaklaşık %91     | Yaklaşık %90        | Yaklaşık 0.29 | Yaklaşık 0.34   | Model kararlı hale gelmiştir.   |
| 10    | Yaklaşık %95     | Yaklaşık %91        | Yaklaşık 0.19 | Yaklaşık 0.30   | Başarılı sonuç elde edilmiştir. |

*Tablo 8. Eğitim grafiğinden okunan yaklaşık epoch bazlı performans değerleri.*




Figure 2 Eğitim ve doğrulama doğruluk eğrisi.




Figure 3 Eğitim ve doğrulama kayıp eğrisi.

## 5. SONUÇLAR VE DEĞERLENDİRME

### 5.1 Test / Doğrulama Performans Metrikleri

Modelin performansı accuracy, precision, recall ve F1-score metrikleri ile değerlendirilmiştir. Sonuçlar sınıf bazlı olarak da incelenmiş ve karışıklık matrisi ile hangi sınıfların birbirine karıştığı analiz edilmiştir.

| Metrik                  | Değer | Yorum                                                       |
|-------------------------|-------|-------------------------------------------------------------|
| Accuracy                | %91   | Modelin genel doğru tahmin oranıdır.                        |
| Precision (Macro)       | 0.90  | Tahmin edilen sınıfların ne kadar doğru olduğunu gösterir.  |
| Recall (Macro)          | 0.91  | Gerçek sınıfların ne kadar yakalandığını gösterir.          |
| F1-Score (Macro)        | 0.90  | Precision ve recall dengesini gösterir.                     |
| Toplam Doğrulama Örneği | 734   | Classification report çıktısındaki toplam destek değeridir. |

Tablo 9. Modelin genel performans metrikleri.

## 5.2 Sınıf Bazlı Performans

| Sınıf        | Precision | Recall | F1-Score | Support |
|--------------|-----------|--------|----------|---------|
| Daisy        | 0.92      | 0.95   | 0.93     | 129     |
| Dandelion    | 0.98      | 0.94   | 0.96     | 176     |
| Roses        | 0.82      | 0.86   | 0.84     | 120     |
| Sunflowers   | 0.92      | 0.91   | 0.91     | 152     |
| Tulips       | 0.88      | 0.88   | 0.88     | 157     |
| Accuracy     | -         | -      | 0.91     | 734     |
| Macro Avg    | 0.90      | 0.91   | 0.90     | 734     |
| Weighted Avg | 0.91      | 0.91   | 0.91     | 734     |

*Tablo 10. Sınıf bazlı precision, recall ve F1-score değerleri.*

Sonuçlara göre en yüksek F1-score değeri 0.96 ile dandelion sınıfında elde edilmiştir. Daisy ve sunflowers sınıfları da yüksek başarı göstermiştir. Roses sınıfının F1-score değeri 0.84 ile diğer sınıflara göre daha düşüktür. Bu durum roses ve tulips gibi bazı çiçek türlerinin renk ve yaprak yapısı bakımından benzerlik göstermesinden kaynaklanabilir.

*Şekil 4. Sınıf bazlı performans sonuçları.*

|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| daisy        | 0.92      | 0.95   | 0.93     | 129     |
| dandelion    | 0.98      | 0.94   | 0.96     | 176     |
| roses        | 0.82      | 0.86   | 0.84     | 120     |
| sunflowers   | 0.92      | 0.91   | 0.91     | 152     |
| tulips       | 0.88      | 0.88   | 0.88     | 157     |
| accuracy     |           |        | 0.91     | 734     |
| macro avg    | 0.90      | 0.91   | 0.90     | 734     |
| weighted avg | 0.91      | 0.91   | 0.91     | 734     |

### 5.3 Karışıklık Matrisi

Karışıklık matrisi, modelin gerçek etiketleri ile tahmin etiketlerini karşılaştırır. Ana köşegen üzerindeki yüksek değerler doğru tahminlerin fazla olduğunu gösterir. Köşegen dışındaki değerler ise modelin hangi sınıfları karıştırdığını belirtir.

| Gerçek / Tahmin | Daisy | Dandelion | Roses | Sunflowers | Tulips |
|-----------------|-------|-----------|-------|------------|--------|
| Daisy           | 122   | 1         | 4     | 0          | 2      |
| Dandelion       | 1     | 165       | 1     | 6          | 3      |
| Roses           | 2     | 1         | 103   | 3          | 11     |
| Sunflowers      | 6     | 1         | 5     | 138        | 2      |
| Tulips          | 2     | 1         | 13    | 3          | 138    |

*Tablo 11. MobileNetV2 modeline ait karışıklık matrisi değerleri.*

Matris incelendiğinde doğru tahminlerin büyük çoğunluğunun ana köşegen üzerinde toplandığı görülmektedir. En fazla karışıklık roses ve tulips sınıfları arasında oluşmuştur. Buna rağmen model genel olarak tüm sınıfları başarılı şekilde ayırt edebilmiştir.



*Şekil 5. MobileNetV2 modeline ait karışıklık matrisi.*

### 5.4 Web Arayüzü ve Örnek Tahmin

Gradio arayüzü ile kullanıcı fotoğraf yükler, sistem görseli 224x224 boyutuna getirir, model tahmin üretir, softmax ile olasılıkları hesaplar ve en yüksek üç sınıfı ekranda gösterir. Örnek testte yüklenen gül fotoğrafı sistem tarafından %99 olasılıkla roses sınıfı olarak tahmin edilmiştir. Bu sonuç modelin gerçek kullanıcı etkileşimiyle çalışabildiğini göstermektedir.



*Şekil 6. Gradio web arayüzünde yapılan örnek tahmin sonucu.*

## 6. TARTIŞMA

### 6.1 Sonuçların Yorumu

Sonuçlar transfer öğrenmenin küçük ve orta ölçekli görüntü veri setlerinde etkili olduğunu göstermektedir. MobileNetV2'nin önceden öğrenilmiş görsel özellikleri kullanması kısa sürede yüksek doğruluk sağlamıştır. Yaklaşık %91 doğruluk, beş sınıflı bir çiçek tanıma görevi için başarılıdır. Ancak gerçek hayatta farklı kamera kaliteleri, ışık koşulları ve arka planlar üzerinde ek testler yapılması sistemin güvenilirliğini artıracaktır.

### 6.2 Güçlü ve Zayıf Yönler

#### Güçlü Yönler

- Transfer öğrenme sayesinde eğitim süresi kısadır.
- Model hafiftir ve hızlı tahmin üretir.
- Gradio arayüzü ile kullanıcı tarafından test edilebilir.
- TensorFlow veri okuma yapısı düzenlidir ve tekrar üretilebilirlik için seed kullanılmıştır.
- Classification report ve confusion matrix ile detaylı performans analizi yapılmıştır.

#### Zayıf Yönler / Sınırlamalar

- Sistem yalnızca 5 çiçek sınıfını tanır.
- Gül ve lale gibi benzer sınıflar bazı fotoğraflarda karışabilir.
- Veri artırma teknikleri eklenirse genelleme kapasitesi artabilir.
- Başarı eğitim veri çeşitliliğine bağlıdır.
- Farklı kamera ve ortam koşullarında ek test yapılması gerekir.

### 6.3 Literatür / Mimari Karşılaştırması

| Model          | Beklenen Başarı | Model Boyutu | Web/Mobil Uygunluğu | Not                                                |
|----------------|-----------------|--------------|---------------------|----------------------------------------------------|
| MobileNetV2    | Yüksek          | Küçük        | Çok uygun           | Bu projede en uygun model olarak seçilmiştir.      |
| VGG16          | Yüksek          | Çok büyük    | Düşük               | Parametre sayısı fazla olduğu için ağırdır.        |
| ResNet50       | Yüksek          | Büyük        | Orta                | Güçlüdür ancak kaynak ihtiyacı daha fazladır.      |
| EfficientNetB0 | Çok yüksek      | Orta         | Uygun               | Doğruluk/verim dengesi iyidir.                     |
| Klasik CNN     | Orta            | Değişken     | Orta                | Sıfırdan eğitim ister; aşırı öğrenme riski vardır. |

*Tablo 12. MobileNetV2 ile diğer mimarilerin genel karşılaştırması.*

### 6.4 İyileştirme Önerileri

1. Veri artırma teknikleri eklenebilir. Örneğin döndürme, yakınlaştırma, parlaklık değişimi ve yatay çevirme uygulanabilir.
2. MobileNetV2 modelinin son katmanlarında fine-tuning yapılabilir.
3. Daha fazla çiçek türü veri setine eklenebilir.
4. Roses ve tulips gibi karışan sınıflar için ek veri toplanabilir.
5. Model TensorFlow Lite formatına dönüştürülerek mobil uygulamaya taşınabilir.
6. Web arayüzüne güven oranı açıklaması ve yanlış tahmin geri bildirimi eklenebilir.

## 7. SONUÇ VE GELECEK ÇALIŞMALAR

Bu projede TensorFlow flower\_photos veri seti kullanılarak beş farklı çiçek türünü tanıyabilen derin öğrenme tabanlı bir görüntü sınıflandırma sistemi geliştirilmiştir. 10 farklı algoritma ve mimari karşılaştırılmış, hız, doğruluk, model boyutu ve uygulamaya uygunluk açısından MobileNetV2 seçilmiştir. MobileNetV2 tabanlı transfer öğrenme modeli 10 epoch eğitilmiş ve yaklaşık %91 doğruluk seviyesine ulaşmıştır.

Geliştirilen Gradio web arayüzü sayesinde kullanıcılar fotoğraf yükleyerek çiçek türü tahmin sonucunu görebilmektedir. Bu yönüyle proje yalnızca teorik bir model eğitimi değil, aynı zamanda gerçek kullanıcıya sunulabilen bir yapay zeka uygulaması olmuştur. Gelecekte veri artırma, fine-tuning, daha fazla çiçek sınıfı ve mobil uygulama entegrasyonu ile sistem geliştirilebilir.

## KAYNAKÇA

- [1] TensorFlow. Flower photos dataset example images. Google Storage / TensorFlow Datasets.
- [2] Sandler, M., Howard, A., Zhu, M., Zhmoginov, A., & Chen, L. C. (2018). MobileNetV2: Inverted Residuals and Linear Bottlenecks. CVPR.
- [3] Deng, J. et al. (2009). ImageNet: A Large-Scale Hierarchical Image Database. CVPR.
- [4] Chollet, F. (2015). Keras. GitHub repository.
- [5] Abid, A. et al. (2019). Gradio: Hassle-Free Sharing and Testing of ML Models in the Wild.
- [6] Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press.

## EKLER

### Ek A: Model Eğitim Kodu Özeti

```
temel_model = tf.keras.applications.MobileNetV2(  
    input_shape=(224, 224, 3),  
    include_top=False,  
    weights="imagenet"  
)  
temel_model.trainable = False  
  
model = tf.keras.Sequential([  
    tf.keras.layers.Rescaling(1./127.5, offset=-1),  
    temel_model,  
    tf.keras.layers.GlobalAveragePooling2D(),  
    tf.keras.layers.Dense(5)  
)  
  
model.compile(  
    optimizer=tf.keras.optimizers.Adam(learning_rate=0.0005),  
    loss=tf.keras.losses.SparseCategoricalCrossentropy(from_logits=True),  
    metrics=["accuracy"]  
)  
  
history = model.fit(train_dataset, epochs=10, validation_data=val_dataset)
```

### Ek B: Kullanılan Kütüphaneler

- tensorflow
- keras
- numpy
- matplotlib
- seaborn
- scikit-learn

- gradio
- PIL

## Ek C: Görsel Yerleşim Listesi

| Şekil   | Görsel                     | Rapordaki Bölüm                 |
|---------|----------------------------|---------------------------------|
| Şekil 1 | Veri seti dağılımı grafiği | 2.2 Sınıf Dağılımı              |
| Şekil 2 | Accuracy grafiği           | 4.3 Eğitim Süreci Gözlemleri    |
| Şekil 3 | Loss grafiği               | 4.3 Eğitim Süreci Gözlemleri    |
| Şekil 4 | Classification Report      | 5.2 Sınıf Bazlı Performans      |
| Şekil 5 | Confusion Matrix           | 5.3 Karışıklık Matrisi          |
| Şekil 6 | Gradio tahmin ekranı       | 5.4 Web Arayüzü ve Örnek Tahmin |

*Tablo 13. Rapora eklenecek görsellerin konumları.*